

# Session 11&12

## Linear Discriminant Analysis (LDA)

NLP | Machine Learning | Zahra Amini

Telegram: @zahraamini\_ai & Instagram:@zahraamini\_ai & LinkedIn: @zahraamini-ai

<https://zil.ink/zahraamini>

طبقه‌بندی و کاهش ابعاد دو مفهوم اساسی در یادگیری ماشین هستند و تکنیک تحلیل افتراقی خطی هر دو این اهداف را به طور مؤثر دنبال می‌کند.

### طبقه‌بندی

طبقه‌بندی یک وظیفه یادگیری تحت نظارت است که هدف آن اختصاص برچسب به داده‌ها بر اساس ویژگی‌های ورودی است به عنوان مثال، در یک مسئله طبقه‌بندی ایمیل، هدف می‌تواند دسته‌بندی ایمیل‌ها به دو دسته "اسپم" یا "غیر اسپم" بر اساس محتوای ایمیل باشد.

هر نقطه داده به یکی از چندین کلاس تعلق دارد، و ما می‌خواهیم از ویژگی‌ها (مانند فراوانی کلمات برای داده‌های متنی) برای پیش‌بینی کلاس استفاده کنیم.

### کاهش ابعاد

در بسیاری از مجموعه داده‌ها، به ویژه در تحلیل متن یا پردازش تصویر، با داده‌های با ابعاد بالا کار می‌کنیم، جایی که تعداد ویژگی‌ها (یا ابعاد) بسیار بیشتر از تعداد نقاط داده است. این فضای با ابعاد بالا می‌تواند به مشکلات زیر منجر شود:

بیش‌بازش: ابعاد بیشتر می‌تواند منجر به مدلی شود که نویز داده‌ها را به خاطر می‌سپارد.  
هزینه محاسباتی: کار کردن در فضاهای با ابعاد بالا هزینه محاسباتی بالایی دارد.

مشکل در تجسم: تجسم داده‌ها با صدھا یا هزاران ویژگی دشوار است.

تکنیک‌های کاهش ابعاد هدفشان این است که تعداد ویژگی‌ها را کاهش دهند، در حالی که مهم‌ترین اطلاعات مورد نیاز برای پیش‌بینی را حفظ کنند.

به ویژه زمانی مفید است که داده‌های دارای برچسب (یعنی کلاس‌ها شناخته شده‌اند) داریم و می‌خواهیم ابعاد را کاهش دهیم در حالی که تفکیک‌پذیری کلاس‌ها حفظ شود. به عبارت ساده، این تکنیک به ما کمک می‌کند داده‌ها را به فضایی با ابعاد کمتر پروژکت کنیم، جایی که داده‌های کلاس‌های مختلف تا حد ممکن از یکدیگر متمایز باشند.

نیاز به LDA

چرا به LDA به  
در مسائل  
طبقه‌بندی  
نیاز داریم؟

تفکیک‌پذیری کلاس‌ها: در بسیاری از موارد، داده‌های با ابعاد بالا ممکن است پیچیده و دشوار برای تجسم باشند. اما در فضاهای با ابعاد کمتر، ممکن است بتوانیم کلاس‌ها را بسیار واضح‌تر جدا کنیم.

به ویژه زمانی مفید است که بخواهیم ترکیب خطی‌ای از ویژگی‌ها را پیدا کنیم که بتواند بهترین تفکیک بین کلاس‌های مختلف را ایجاد کند.

LDA چگونه این  
کار را انجام  
می‌دهد؟

به واریانس بین کلاس‌ها (یعنی تفاوت کلاس‌ها با یکدیگر) و واریانس درون کلاس‌ها (یعنی میزان پراکندگی نقاط داده هر کلاس در خودشان) نگاه می‌کند.

هدف این است که واریانس بین کلاس‌ها را به حداقل و واریانس درون کلاس‌ها را به حداقل برسانیم.

## طبقه‌بندی ایمیل‌ها (اسپیم در مقابل غیر اسپیم)

مثال

هر ایمیل می‌تواند با مجموعه‌ای از ویژگی‌ها نشان داده شود. برای مثال:  
 فراوانی کلمات (مثلًا چند بار کلماتی مانند "رایگان"، "پیشنهاد"، "بخر" ظاهر می‌شوند)  
 طول ایمیل  
 حضور برخی کلمات کلیدی خاص

فضای با ابعاد بالا:  
 این ویژگی‌ها می‌توانند یک فضای با ابعاد بالا تشکیل دهند. تصور کنید که ما ۱۰۰۰ کلمه مختلف در مجموعه داده خود داریم و هر ایمیل با یک بردار ۱۰۰۰ بعدی نشان داده می‌شود (هر بعد نشان دهنده فراوانی یک کلمه خاص است). در این حالت، تفکیک ایمیل‌های اسپیم از غیر اسپیم دشوار می‌شود

کاربرد LDA  
 به ما کمک می‌کند تا این ابعاد را کاهش دهیم، در حالی که جداسازی بین اسپیم و غیر اسپیم تا حد ممکن واضح باقی بماند  
 می‌تواند داده‌ها را به فضایی با ابعاد کمتر (مثلًا ۲ یا ۳ بعد) پروژکت کند، جایی که ایمیل‌های اسپیم LDA، به جای کار با ۱۰۰۰ ویژگی کامل و غیر اسپیم متمایزتر و راحت‌تر قابل طبقه‌بندی باشند

هدف اصلی تحلیل افتراقی خطی این است که داده‌های با ابعاد بالا به فضای با ابعاد پایین‌تر پروژه کنیم در حالی که حداکثر جداسازی بین کلاس‌ها را حفظ کنیم. این کار با حداکثر کردن نسبت واریانس بین کلاس‌ها به واریانس درون کلاس‌ها در فضای پروژه شده انجام می‌شود

واریانس درون کلاس‌ها  $\rightarrow S_w$   
 این مقدار نشان‌دهنده تغییرات داده‌ها در داخل هر کلاس است، یعنی چگونه داده‌ها در هر کلاس حول میانگین خود پراکنده می‌شوند

واریانس بین کلاس‌ها  $\rightarrow S_B$   
 این مقدار نشان‌دهنده تفاوت میانگین هر کلاس با میانگین کلی داده‌ها است

تابع هدف LDA یک بردار پروجکشن  $w$  پیدا می‌کند که نسبت واریانس بین کلاس‌ها به واریانس درون کلاس‌ها را حداکثر کند

 $\max$ 

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

$$S_W = \sum_{k=1}^K \sum_{x_i \in C_k} (x_i - \mu_k)(x_i - \mu_k)^T$$

$$S_B = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^T$$

- $x_1$ : Frequency of "buy".
- $x_2$ : Frequency of "offer".

Data points are as follows:

Class	$x_1$	$x_2$
A	1	2
A	2	3
A	3	4
B	5	6
B	6	8
B	7	8

### 1. Compute Class Means ( $\mu_k$ )

For Class A:

$$\mu_A = \frac{1}{3} \begin{bmatrix} 1 + 2 + 3 \\ 2 + 3 + 4 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$$

For Class B:

$$\mu_B = \frac{1}{3} \begin{bmatrix} 5 + 6 + 7 \\ 6 + 8 + 8 \end{bmatrix} = \begin{bmatrix} 6 \\ 7.33 \end{bmatrix}$$

Overall mean ( $\mu$ ):

$$\mu = \frac{1}{6} \begin{bmatrix} 1 + 2 + 3 + 5 + 6 + 7 \\ 2 + 3 + 4 + 6 + 8 + 8 \end{bmatrix} = \begin{bmatrix} 4 \\ 5.33 \end{bmatrix}$$

### 3. Compute the Scatter Matrices

Within-Class Scatter Matrix ( $S_W$ ):

The within-class scatter matrix measures the variance within each class. For each class:

$$S_{W,k} = \sum_{x_i \in C_k} (x_i - \mu_k)(x_i - \mu_k)^T$$

For Class A:

$$\begin{aligned} S_{W,A} &= (x_1 - \mu_A)(x_1 - \mu_A)^T + (x_2 - \mu_A)(x_2 - \mu_A)^T + (x_3 - \mu_A)(x_3 - \mu_A)^T \\ &= \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} -1 & -1 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} \end{aligned}$$

For Class B:

$$\begin{aligned} S_{W,B} &= \begin{bmatrix} -1 & -1.33 \\ -1 & -1.33 \end{bmatrix} \begin{bmatrix} -1 & -1.33 \end{bmatrix} + \dots \\ &= \begin{bmatrix} 6 & 8 \\ 8 & 10.66 \end{bmatrix} \end{aligned}$$

Combine  $S_W$ :

$$S_W = S_{W,A} + S_{W,B} = \begin{bmatrix} 8 & 10 \\ 10 & 12.66 \end{bmatrix}$$

### Between-Class Scatter Matrix ( $S_B$ ):

The between-class scatter matrix measures the variance of the class means relative to the overall mean:

$$S_B = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^T$$

For both classes:

$$S_B = 3 \begin{bmatrix} -2 & -2.33 \\ -2 & -2.33 \end{bmatrix} \begin{bmatrix} -2 & -2.33 \end{bmatrix} + 3 \begin{bmatrix} 2 & 2.33 \\ 2 & 2.33 \end{bmatrix} \begin{bmatrix} 2 & 2.33 \end{bmatrix}$$

$$S_B = \begin{bmatrix} 12 & 14 \\ 14 & 16.66 \end{bmatrix}$$

## Solving the Eigenvalue Problem

### Step 1: Compute $S_W^{-1}$

We already have the within-class scatter matrix  $S_W$ :

$$S_W = \begin{bmatrix} 8 & 10 \\ 10 & 12.66 \end{bmatrix}$$

We can compute its inverse using the formula for the inverse of a 2x2 matrix:

$$S_W^{-1} = \frac{1}{\det(S_W)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

Where for a matrix  $\begin{bmatrix} a & b \\ c & d \end{bmatrix}$ , the determinant is:

$$\det(S_W) = ad - bc$$

For the matrix  $S_W = \begin{bmatrix} 8 & 10 \\ 10 & 12.66 \end{bmatrix}$ , we compute the determinant:

$$\det(S_W) = (8 \times 12.66) - (10 \times 10) = 101.28 - 100 = 1.28$$

Thus, the inverse of  $S_W$  is:

$$S_W^{-1} = \frac{1}{1.28} \begin{bmatrix} 12.66 & -10 \\ -10 & 8 \end{bmatrix} = \begin{bmatrix} 9.89 & -7.81 \\ -7.81 & 6.25 \end{bmatrix}$$

## Step 2: Form the Matrix Equation

Now, we have the following equation to solve for  $w$ :

$$S_W^{-1} S_B w = \lambda w$$

Where  $S_B = \begin{bmatrix} 12 & 14 \\ 14 & 16.66 \end{bmatrix}$ .

We need to multiply  $S_W^{-1}$  with  $S_B$ :

$$S_W^{-1} S_B = \begin{bmatrix} 9.89 & -7.81 \\ -7.81 & 6.25 \end{bmatrix} \begin{bmatrix} 12 & 14 \\ 14 & 16.66 \end{bmatrix}$$

Performing the matrix multiplication:

$$S_W^{-1} S_B = \begin{bmatrix} (9.89 \times 12) + (-7.81 \times 14) & (9.89 \times 14) + (-7.81 \times 16.66) \\ (-7.81 \times 12) + (6.25 \times 14) & (-7.81 \times 14) + (6.25 \times 16.66) \end{bmatrix}$$

$$S_W^{-1} S_B = \begin{bmatrix} 118.68 - 109.34 & 138.46 - 129.56 \\ -93.72 + 87.5 & -109.34 + 104.17 \end{bmatrix}$$

$$S_W^{-1} S_B = \begin{bmatrix} 9.34 & 8.90 \\ -6.22 & -5.17 \end{bmatrix}$$

### Step 3: Find the Eigenvalues and Eigenvectors

Now, we need to find the eigenvalues and eigenvectors of the matrix  $S_W^{-1}S_B$ :

$$A = \begin{bmatrix} 9.34 & 8.90 \\ -6.22 & -5.17 \end{bmatrix}$$

To find the eigenvalues, we solve the characteristic equation:

$$\det(A - \lambda I) = 0$$

Where  $I$  is the identity matrix, and  $\lambda$  is the eigenvalue.

$$\det \left( \begin{bmatrix} 9.34 - \lambda & 8.90 \\ -6.22 & -5.17 - \lambda \end{bmatrix} \right) = 0$$

This expands to:

$$(9.34 - \lambda)(-5.17 - \lambda) - (-6.22)(8.90) = 0$$

Simplifying the determinant:

$$(9.34 - \lambda)(-5.17 - \lambda) + 55.4 = 0$$

Expanding:

$$\lambda^2 - 4.17\lambda - 48.3 + 55.4 = 0$$

$$\lambda^2 - 4.17\lambda + 7.1 = 0$$

For  $a = 1$ ,  $b = -4.17$ , and  $c = 7.1$ , we get:

$$\lambda = \frac{-(-4.17) \pm \sqrt{(-4.17)^2 - 4(1)(7.1)}}{2(1)}$$

Now we solve this quadratic equation for  $\lambda$  using the quadratic formula:

$$\lambda = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

$$\lambda = \frac{4.17 \pm \sqrt{17.39 - 28.4}}{2}$$

$$\lambda = \frac{4.17 \pm \sqrt{-11.01}}{2}$$

Thus, the two possible eigenvalues are:

$$\lambda_1 = \frac{4.17 + 6.76}{2} = 5.465$$

$$\lambda_2 = \frac{4.17 - 6.76}{2} = -1.295$$

Since the eigenvalues must be **real and positive**, we choose the eigenvalue:

$$\lambda_1 = 5.465$$

#### 4. Eigenvector Calculation

Now, we find the eigenvector  $w$  corresponding to the largest eigenvalue  $\lambda_1 = 5.465$ . To do this, we substitute the eigenvalue into the equation:

$$(S_W^{-1} S_B - \lambda_1 I)w = 0$$

Substitute  $\lambda_1 = 5.465$  into the matrix  $S_W^{-1} S_B - \lambda_1 I$ :

$$S_W^{-1} S_B - 5.465 I = \begin{bmatrix} 9.34 - 5.465 & 8.90 \\ -6.22 & -5.17 - 5.465 \end{bmatrix}$$

This gives:

$$= \begin{bmatrix} 3.875 & 8.90 \\ -6.22 & -10.635 \end{bmatrix}$$

Now, solve for  $w$  by solving the system of equations:

$$\begin{bmatrix} 3.875 & 8.90 \\ -6.22 & -10.635 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = 0$$

This represents two linear equations:

$$1. \quad 3.875w_1 + 8.90w_2 = 0$$

$$2. \quad -6.22w_1 - 10.635w_2 = 0$$

### Step 1: Express $w_1$ in terms of $w_2$ (or vice versa)

We can start by solving the first equation for  $w_1$  in terms of  $w_2$ :

$$3.875w_1 = -8.90w_2$$

$$w_1 = \frac{-8.90}{3.875}w_2$$

$$w_1 = -2.295w_2$$

### Step 2: Substitute into the second equation

Now, substitute  $w_1 = -2.295w_2$  into the second equation:

$$-6.22(-2.295w_2) - 10.635w_2 = 0$$

$$(6.22 \times 2.295)w_2 - 10.635w_2 = 0$$

$$14.26w_2 - 10.635w_2 = 0$$

$$3.625w_2 = 0$$

$$w_2 = 0$$

### Step 3: Solve for $w_1$

Now, since  $w_2 = 0$ , substitute this into the equation  $w_1 = -2.295w_2$ :

$$w_1 = -2.295(0) = 0$$

Thus, the solution we get is:

$$w_1 = 0, \quad w_2 = 0$$

## 5. Select the Top k Eigenvectors

In this case, since we want a 1D projection, select the eigenvector corresponding to the largest eigenvalue:

$$w = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$$

## 6. Projection

Each data point  $x_i$  is projected onto the direction  $w$  using:

$$y_i = w^T x_i$$

For example: For  $x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ :

$$y_1 = w^T x_1$$

Repeat for all points to obtain their projections in 1D space.

Suppose we have the following data point:

$$x_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

And the eigenvector  $w$  corresponding to the largest eigenvalue is:

$$w = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$$

To compute  $y_1$ , we first calculate the dot product  $w^T x_1$ :

$$y_1 = w^T x_1 = [3 \quad 4] \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$y_1 = 3 \times 1 + 4 \times 2 = 3 + 8 = 11$$

Therefore, the projection of  $x_1$  onto the eigenvector  $w$  is  $y_1 = 11$ .

## Repeat for All Data Points

This process is repeated for each data point  $x_i$  to obtain its projection in the 1D space. For example, if we have the following additional data points:

$$x_2 = \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 5 \\ 6 \end{bmatrix}$$

We can calculate their projections using the formula  $y_i = w^T x_i$ .