

# Session 1&2

## Backpropagation in NN

**Deep Learning | Zahra Amini**

Telegram: @zahraamini\_ai & Instagram:@zahraamini\_ai & LinkedIn: @zahraamini-ai

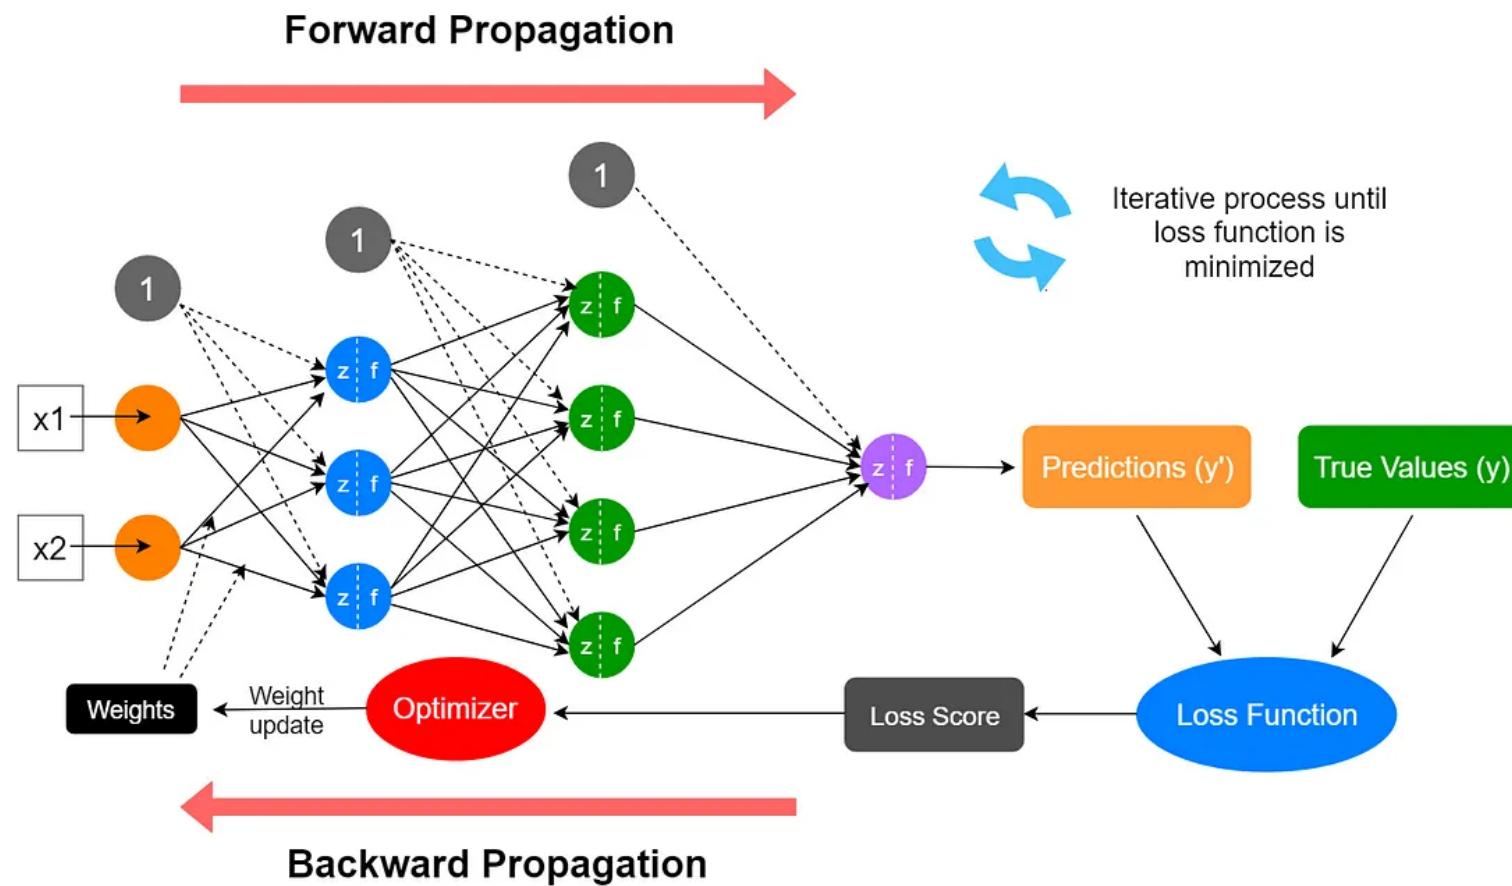
<https://zil.ink/zahraamini>

یادگیری در نورون مصنوعی چیست؟

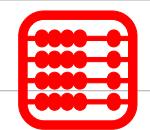
یادگیری در نورون مصنوعی فرآیندی است که در آن مدل با تنظیم پارامترهای داخلی خود از

طریق به روزرسانی وزن‌ها و بهینه‌سازی تابع خطا، توانایی تشخیص و پیش‌بینی الگوهای در

داده‌های ورودی را به دست می‌آورد



# Gradient



:

گرادیان در ریاضیات و به ویژه در زمینه بهینه‌سازی و یادگیری ماشین، نشان‌دهنده شبیب یا نرخ تغییرات یک تابع در یک نقطه خاص است. به عبارت ساده‌تر، گرادیان برداری است که نشان می‌دهد چگونه مقدار تابع در یک نقطه خاص تغییر می‌کند و در چه جهتی این تغییرات بیشترین مقدار را دارد.

$$\text{Gradiant} \rightsquigarrow \nabla f(x, y) = \frac{\partial f}{\partial x} \hat{x} + \frac{\partial f}{\partial y} \hat{y}$$

$$f(x, y) = x^2 + y^2 \rightsquigarrow \nabla f = 2x \hat{x} + 2y \hat{y}$$

$$f(x, y) = x^2 + y^2 \rightsquigarrow \begin{cases} \frac{\partial f}{\partial x} = 2x \\ \frac{\partial f}{\partial y} = 2y \end{cases}$$

مشتق جزئی

$$\left\{ \begin{array}{l} y = 8z^3 + z^2 + 5 \\ z = x^5 + 9 \end{array} \right. \rightsquigarrow \frac{\partial y}{\partial x} = ? \rightsquigarrow \text{مشتق زنجیره‌ای}$$

$$\frac{\partial y}{\partial x} = \frac{\partial y}{\partial z} \frac{\partial z}{\partial x}$$

# Gradient Descent

1 مقدار دهی اولیه یا رامترها ← شا رابه صورت رسیدن مقدار دهی می کنیم

2 حاصله کرایان ← از تابع Loss سبست نه استقیمی کنیم.

$$W_{\text{new}} = W_{\text{old}} - \alpha \frac{\delta L}{\delta W_{\text{old}}}$$

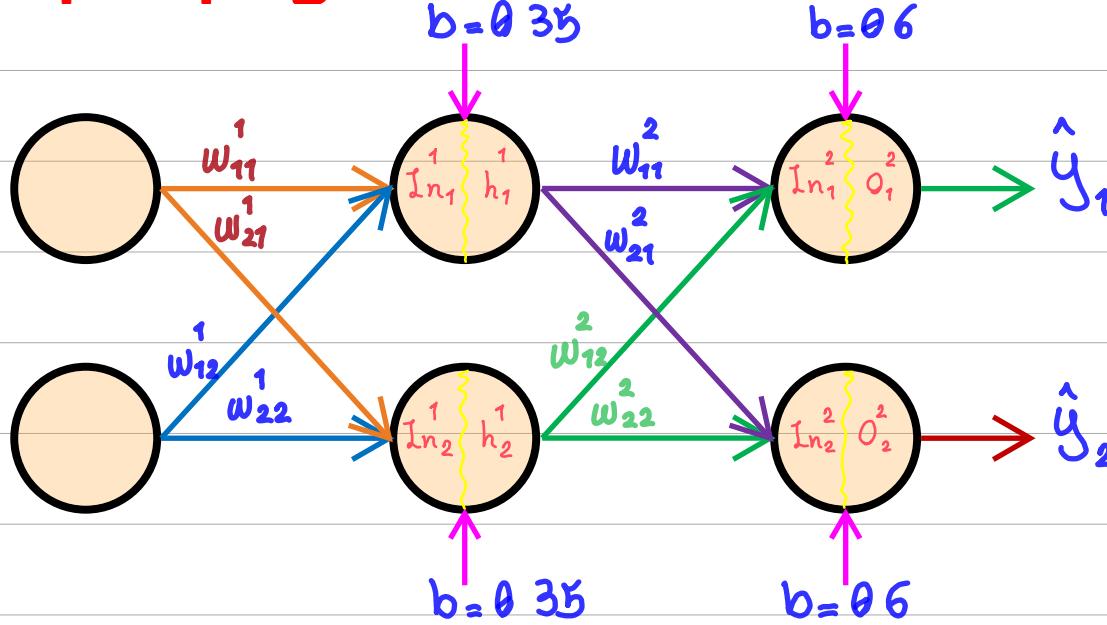
3 آندیت وزکا ←

4 ترتیب حاصله ← مرحله 3,2 را ترسیم نهادن و حدی داشم

# Backpropagation in MLP



$$x_1 = 0.05, x_2 = 0.1$$



$$W^1 = \begin{bmatrix} 0.15 & 0.2 \\ 0.25 & 0.3 \end{bmatrix} \quad W^2 = \begin{bmatrix} 0.4 & 0.45 \\ 0.5 & 0.55 \end{bmatrix}$$

$$b^1 = 0.35, b^2 = 0.6 \quad \hat{y}_1 = 0.01, \hat{y}_2 = 0.99$$

Activation Function  $f^1 = \text{ReLU}$   $f^2 = \text{Sigmoid}$

? Update  $W_{11}^1$  via SGD  $\alpha = 0.1$

- ① Feed Forward
- ② Loss Function
- ③ Back Propagation

## ① Feed Forward:

$$\text{In}_1^1 = W_{11}^1 x_1 + W_{12}^1 x_2 + b^1 = 0.3375 \rightarrow h_1^1 = \text{ReLU}(\text{In}_1^1) = 0.3375$$

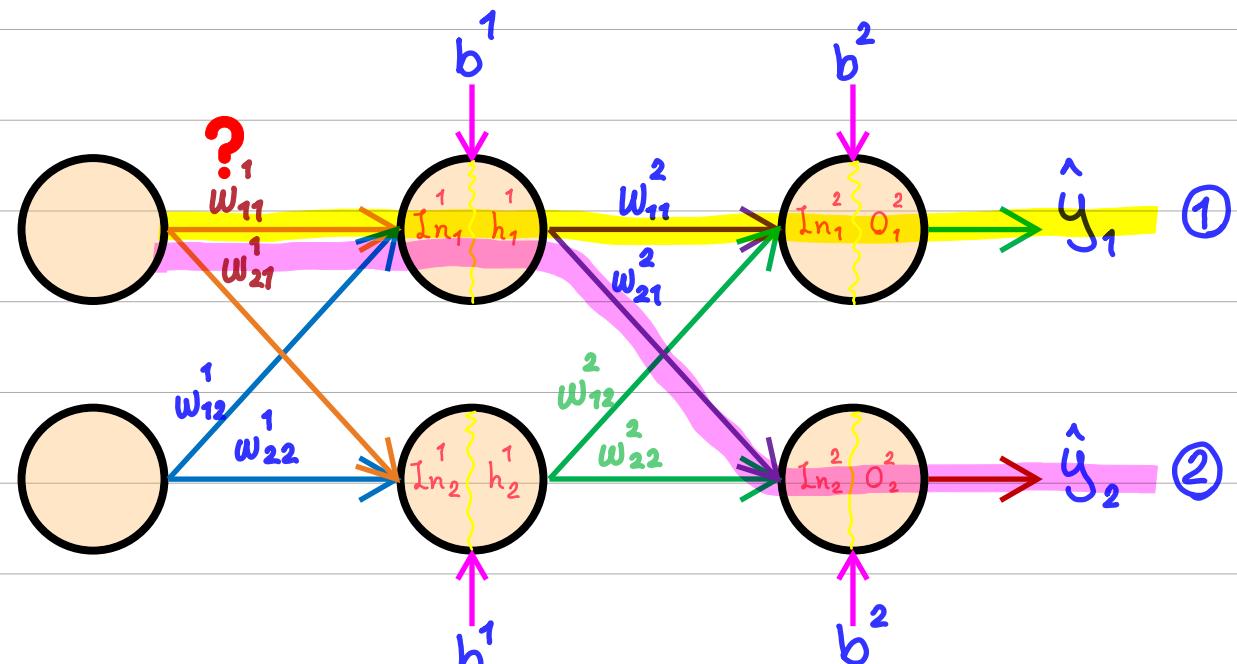
$$\text{In}_2^1 = W_{21}^1 x_1 + W_{22}^1 x_2 + b^1 = 0.3925 \rightarrow h_2^1 = \text{ReLU}(\text{In}_2^1) = 0.3925$$

$$\begin{aligned} \text{In}_1^2 &= W_{11}^2 h_1^1 + W_{12}^2 h_2^1 + b^2 = 0.45 \cdot 0.3375 + 0.45 \cdot 0.3925 + 0.6 = 0.92 \\ \text{In}_2^2 &= W_{21}^2 h_1^1 + W_{22}^2 h_2^1 + b^2 = 0.55 \cdot 0.3375 + 0.55 \cdot 0.3925 + 0.6 = 1.004 \end{aligned}$$

$$\begin{aligned} O_1^2 &= \text{Sigmoid}(\text{In}_1^2) = \hat{y}_1 = 0.92 \\ O_2^2 &= \text{Sigmoid}(\text{In}_2^2) = \hat{y}_2 = 1.004 \end{aligned}$$

② Loss Function  $\rightarrow \text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$  وارد شده میکار آمیخته کند Sample ~ SGD ✓

③ Back Propagation



$$\frac{\partial L}{\partial w_{11}} = ① + ② = \left[ \frac{\partial L}{\partial \hat{y}_1} \frac{\partial \hat{y}_1}{\partial O_1^2} \frac{\partial O_1^2}{\partial In_1^2} \frac{\partial In_1^2}{\partial h_1^1} \frac{\partial h_1^1}{\partial In_1^1} \frac{\partial In_1^1}{\partial w_{11}} \right] + \left[ \frac{\partial L}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial O_2^2} \frac{\partial O_2^2}{\partial In_2^2} \frac{\partial In_2^2}{\partial h_2^1} \frac{\partial h_2^1}{\partial In_1^1} \frac{\partial In_1^1}{\partial w_{11}} \right]$$

$$\frac{\partial L}{\partial w_{11}} = \left[ \frac{\partial L}{\partial \hat{y}_1} \frac{\partial \hat{y}_1}{\partial O_1^2} \frac{\partial O_1^2}{\partial In_1^2} \frac{\partial In_1^2}{\partial h_1^1} + \frac{\partial L}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial O_2^2} \frac{\partial O_2^2}{\partial In_2^2} \frac{\partial In_2^2}{\partial h_2^1} \right] \left[ \frac{\partial h_1^1}{\partial In_1^1} \frac{\partial In_1^1}{\partial w_{11}} \right]$$

$$* (ab + b.c) = b(a+c)$$

$$\frac{\partial L}{\partial w_{11}^1} = \left[ \frac{\partial L}{\partial \hat{y}_1} \frac{\partial \hat{y}_1}{\partial O_1^2} \frac{\partial O_1^2}{\partial \ln_1^2} \frac{\partial \ln_1^2}{\partial h_1^1} + \frac{\partial L}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial O_2^2} \frac{\partial O_2^2}{\partial \ln_2^2} \frac{\partial \ln_2^2}{\partial h_1^1} \right] \begin{bmatrix} \frac{1}{\partial \ln_1^1} & \frac{\partial \ln_1^1}{\partial w_{11}^1} \end{bmatrix}$$

① Feed Forward:

$$\ln_1^1 = w_{11}^1 x_1 + w_{12}^1 x_2 + b^1 \rightarrow h_1^1 = \text{ReLU}(\ln_1^1)$$

$$\ln_2^1 = w_{21}^1 h_1^1 + w_{22}^1 h_2^1 + b^2 \rightarrow h_2^1 = \text{ReLU}(\ln_2^1)$$

$$\ln_1^2 = w_{11}^2 h_1^1 + w_{12}^2 h_2^1 + b^2 \rightarrow O_1^2 = \text{Sigmoid}(\ln_1^2) = \hat{y}_1$$

$$\ln_2^2 = w_{21}^2 h_1^1 + w_{22}^2 h_2^1 + b^2 \rightarrow O_2^2 = \text{Sigmoid}(\ln_2^2) = \hat{y}_2$$

$$\frac{\partial \ln_1^1}{\partial w_{11}^1} = \frac{\partial}{\partial w_{11}^1} (w_{11}^1 x_1 + \cancel{w_{12}^1 x_2 + b^1}) = x_1$$

$$\frac{\partial \ln_1^2}{\partial h_1^1} = \frac{\partial}{\partial h_1^1} (w_{11}^2 h_1^1 + \cancel{w_{12}^2 h_2^1 + b^2}) = w_{11}^2$$

$$\frac{\partial h_1^1}{\partial \ln_1^1} = \frac{\partial}{\partial \ln_1^1} (\text{ReLU}(\ln_1^1)) = \begin{cases} 1 & \ln_1^1 > 0 \\ 0 & \ln_1^1 < 0 \\ \text{Undefined} & \ln_1^1 = 0 \end{cases}$$

\*  $\text{ReLU}(x) = \begin{cases} x & x > 0 \\ 0 & x \leq 0 \end{cases}$

$$\frac{\partial O_1^2}{\partial \ln_1^2} = \frac{\partial}{\partial \ln_1^2} (\text{Sigmoid}(\ln_1^2)) = \sigma'(\ln_1^2) \times (1 - \sigma'(\ln_1^2))$$

$$\frac{\partial \ln_2^2}{\partial h_1^1} = \frac{\partial}{\partial h_1^1} (w_{21}^2 h_1^1 + \cancel{w_{22}^2 h_2^1 + b^2}) = w_{21}^2$$

$$\frac{\partial \hat{y}_1}{\partial O_1^2} = 1$$

$$\frac{\partial O_2^2}{\partial \ln_2^2} = \frac{\partial}{\partial \ln_2^2} (\text{Sigmoid}(\ln_2^2)) = \sigma'(\ln_2^2) \times (1 - \sigma'(\ln_2^2))$$

$$\frac{\partial L}{\partial \hat{y}_1} = \frac{\partial}{\partial \hat{y}_1} \left( \frac{1}{m} \sum (y - \hat{y})^2 \right) = -\frac{2}{m} \sum (y - \hat{y})$$

$$\frac{\partial \hat{y}_2}{\partial O_2^2} = 1$$

$$\frac{\partial L}{\partial \hat{y}_2} = \frac{\partial}{\partial \hat{y}_2} \left( \frac{1}{m} \sum (y - \hat{y})^2 \right) = -\frac{2}{m} \sum (y - \hat{y})$$

\*  $(f^2)' = f \cdot f'$

$$\frac{\partial L}{\partial w_{11}^1} = \left[ \begin{array}{cccccc} \frac{\partial L}{\partial \hat{y}_1} & \frac{\partial \hat{y}_1}{\partial h_1^2} & \frac{\partial O_1^1}{\partial h_1^2} & \frac{\partial I_{n1}^2}{\partial h_1^1} & + & \frac{\partial L}{\partial \hat{y}_2} \\ -0.249 & 1 & 0 & 0.187 & 0.4 & -0.217 \\ \end{array} \right] \left[ \begin{array}{cc} \frac{\partial h_1^1}{\partial I_{n1}^1} & \frac{\partial I_{n1}^1}{\partial w_{11}^1} \\ 0.3375 & 0.05 \end{array} \right] \simeq -0.0006647$$

$$\frac{\partial I_{n1}^1}{\partial w_{11}^1} = \frac{\partial}{\partial w_{11}^1} \left( w_{11}^1 x_1 + w_{12}^1 x_2 + b^1 \right) = x_1 = 0.05$$

$$\frac{\partial h_1^1}{\partial I_{n1}^1} = \frac{\partial}{\partial I_{n1}^1} \left( \text{ReLU}(I_{n1}^1) \right) = \begin{cases} 1 & I_{n1}^1 > 0 \\ 0 & I_{n1}^1 < 0 \\ \text{Undefined} & I_{n1}^1 = 0 \end{cases} = 0.3375$$

$$\frac{\partial I_{n2}^2}{\partial h_1^1} = \frac{\partial}{\partial h_1^1} \left( w_{21}^2 h_1^1 + w_{22}^2 h_2^1 + b^2 \right) = w_{21}^2 = 0.55$$

$$\frac{\partial O_1^1}{\partial I_{n1}^2} = \frac{\partial}{\partial I_{n1}^2} \left( \text{Sigmoid}(I_{n1}^2) \right) = \sigma(I_{n1}^2) \times (1 - \sigma(I_{n1}^2)) = 0.174$$

$$\frac{\partial \hat{y}_1}{\partial O_1^1} = 1$$

$$\frac{\partial L}{\partial \hat{y}_2} = \frac{\partial}{\partial \hat{y}_2} \left( \frac{1}{m} \sum (y - \hat{y})^2 \right) = -\frac{2}{m} \sum (y - \hat{y}) = -0.217$$

$$\frac{\partial I_{n2}^2}{\partial h_1^1} = \frac{\partial}{\partial h_1^1} \left( w_{21}^2 h_1^1 + w_{22}^2 h_2^1 + b^2 \right) = w_{21}^2 = 0.4 = 0.187$$

$$\frac{\partial O_2^2}{\partial I_{n2}^2} = \frac{\partial}{\partial I_{n2}^2} \left( \text{Sigmoid}(I_{n2}^2) \right) = \sigma(I_{n2}^2) \times (1 - \sigma(I_{n2}^2))$$

$$\frac{\partial \hat{y}_2}{\partial O_2^2} = 1 = -0.249$$

$$\frac{\partial L}{\partial \hat{y}_1} = \frac{\partial}{\partial \hat{y}_2} \left( \frac{1}{m} \sum (y - \hat{y})^2 \right) = -\frac{1}{m} \sum (y - \hat{y})^{0.751}$$

$$W_{\text{new}} = W_{\text{old}} - \alpha \frac{\partial L}{\partial W_{\text{old}}}$$

$$W_{11}^1_{\text{new}} = 0.15 - (0.1 \times (-0.0006647)) = 0.15006647$$

## پارامترها

پارامترها مقادیر داخلی یک مدل یادگیری ماشین هستند که در طی فرایند آموزش مدل از داده‌ها، یاد گرفته (تنظیم) می‌شوند. این پارامترها معمولاً وزن‌ها و بایاس‌ها در مدل‌های شبکه عصبی یا ضرایب در مدل‌های رگرسیون هستند. پارامترها مستقیماً از داده‌های آموزشی استخراج می‌شوند و مقادیرشان به طور خودکار تنظیم می‌شود تا مدل بتواند عملکرد بهتری روی داده‌های آموزشی داشته باشد

وزن‌ها در شبکه‌های عصبی (weights)

بایاس‌ها در شبکه‌های عصبی (biases)

# هایپرپارامترها

هایپرپارامترها مقادیری هستند که قبل از فرایند آموزش مدل تعیین می‌شوند و بر روی فرایند آموزش و ساختار مدل تأثیر می‌گذارند. هایپرپارامترها توسط انسان یا به کمک روش‌های جستجوی هایپرپارامتر مانند گرید سرچ یا جستجوی تصادفی تنظیم می‌شوند. تنظیم درست هایپرپارامترها می‌تواند تأثیر بزرگی بر عملکرد نهایی مدل داشته باشد

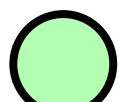
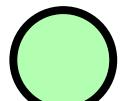
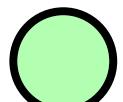
مثال‌هایی از هایپرپارامترها

نرخ یادگیری (learningrate)

تعداد لایه‌ها و نورون‌ها در هر لایه (numberoflayers و numberofneuronsperlayer) (batchsize) اندازه بچ، تعداد نمونه‌هایی که قبل از به‌روزرسانی وزن‌ها در طول یک مرحله آموزش پردازش می‌شوند

تعداد دوره‌های آموزش، تعداد تکرارهای کامل روی داده‌های آموزشی در طول آموزش (numberofepochs)

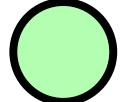
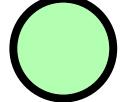
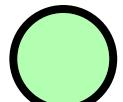
Input Layer



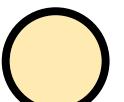
•

•

•



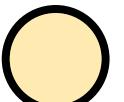
Hidden Layer



•

•

•



•

•

•



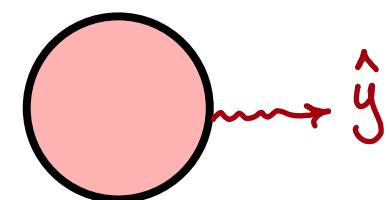
•

•

•



Output Layer



1 Neurons

300 Neurons 512 Neurons 256 Neurons 128 Neurons

\* fully connected layer